不瞎编的私有知识库问答助手

姓名：温定浩 学号：2245014148 日期：2026-10-20

摘要：本实验实现了一个最小可用的个人知识库 RAG 问答助手，支持 PDF、Markdown、TXT 导入，采用 300 字切分，可在运行时切换 BM25 与 bge-small-zh 向量检索。生成阶段强制标注原文出处，并用“检索阈值 + 提示词约束”两层机制实现拒答。用自建 20 题（10 文档题、5 多跳题、5 陷阱题）对两种检索各跑一遍，从答案正确率、幻觉率、Top-3 命中率和首 token 延迟四个维度比较，定位了“证据齐全仍答错”和“近域陷阱被硬编”两类失败。

关键词：检索增强生成；BM25；向量检索；拒答；引用溯源；评测

1 系统架构

系统分四层。**语料层**把 PDF、Markdown、TXT 解析为统一文本，按段落/句子切分并在相邻片段间保留整句重叠。**索引层**为同一批片段分别建立 BM25 倒排统计与 512 维归一化向量索引，向量由本地 bge-small-zh-v1.5（fastembed，CPU）生成。**检索层**用统一的 search(query, top_k) 接口封装两个检索器，CLI 与 Web 只改一个参数即可切换。**生成层**把 Top-4 片段编号后拼进提示词，要求关键结论标注 [n]；程序只接受落在候选范围内的编号，再按句核验该片段是否真的支撑这句话，最后还原为“文档名 + 片段号 + 原文”。

拒答有两道闸门：检索层用向量 Top-1 相似度（< 0.40）或 BM25 查询词覆盖率（< 0.30）挡住明显域外问题；生成层要求模型在资料不足时只输出 INSUFFICIENT_CONTEXT，程序同时识别中英文拒答措辞。第一层不调用模型、延迟低，第二层负责“词面相关但实际答不了”的陷阱。

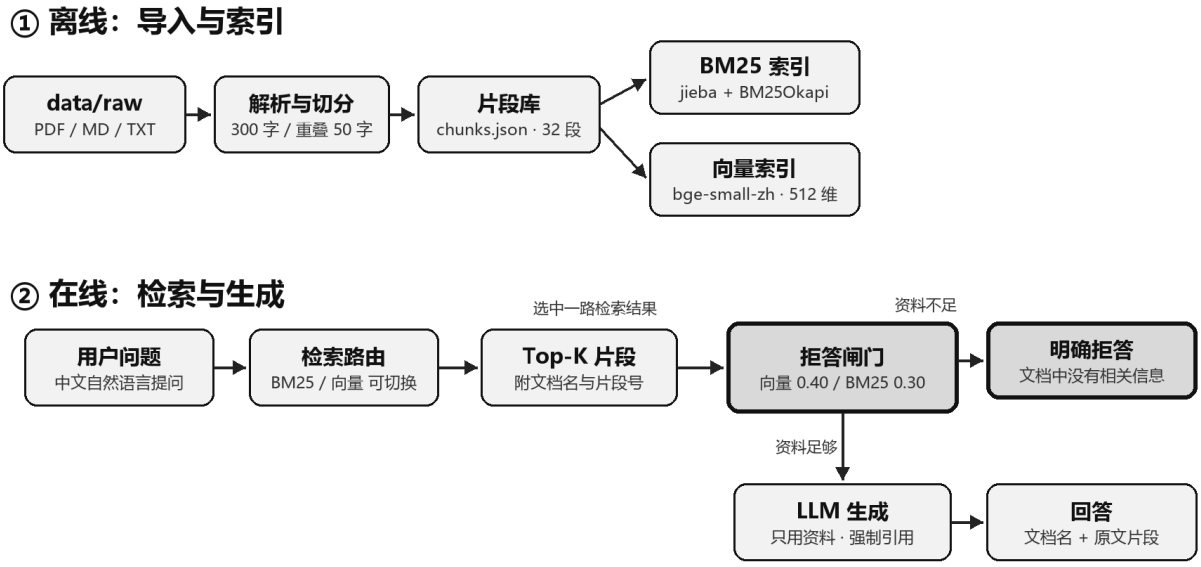


图 1 系统架构：语料导入、双索引检索、带引用校验的生成与两层拒答

2 实验设置

表 1 实验设置

项目	设置
语料	3 个文档、5 781 字符、2 种格式；最长一篇纯汉字 1 530，口径见 data/README.md
切分	300 字 / 约 50 字整句重叠；3 个文档共 32 个片段；依据日记中 8 题实验：200/300/500 字 Top-3 命中 5/8、7/8、6/8
关键词检索	jieba 搜索模式分词 + rank-bm25 BM25Okapi，Top-4
向量检索	BAAI/bge-small-zh-v1.5，512 维，余弦相似度，Top-4
生成	OpenAI 兼容接口（测试用 Pollinations openai-fast），temperature=0，流式输出
拒答阈值	向量 Top-1 < 0.40；BM25 覆盖率 < 0.30；在这 20 题上校准（in-sample，限制见 3.1）
评测集	20 题：10 文档题、5 多跳题、5 陷阱题；每题标注标准答案、来源文档、原文 evidence
环境	Windows 11，i5-12400 / 16 GB / 无显卡；Python 3.13.9、gradio 6.30.0、fastembed 0.9.0

3 评测结果

3.1 四项指标

表 2 两种检索方案的四项指标

指标	BM25	向量检索
答案正确率	90%（18/20）	90%（18/20）
幻觉率（5 道陷阱题）	20%（1/5）	0%（0/5）
Top-3 检索命中率	86.7%（13/15）	86.7%（13/15）
首次回答平均延迟（首 token）	9.76 s	8.77 s
端到端平均延迟（参考）	10.42 s	9.14 s
引用给出率	93.3%（14/15）	100%（14/14）
引用文档准确率	100%	100%

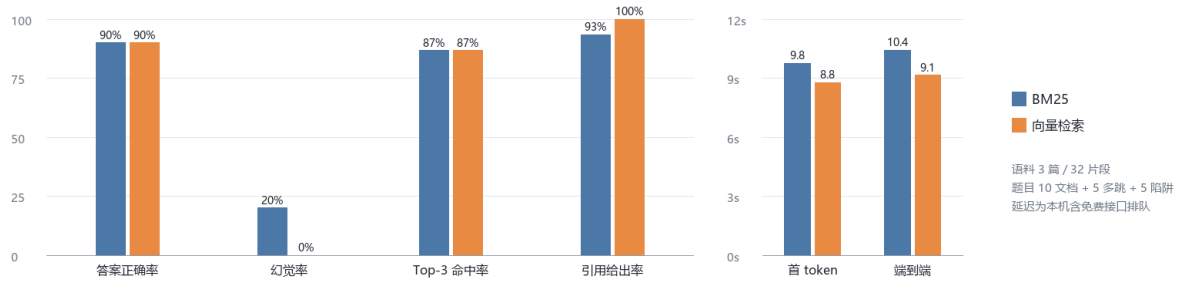


图 2 四项指标与延迟对比：正确率、命中率完全打平，差异只在幻觉率与延迟

两者都答对 18/20，但错在不同的题：BM25 错 q11（比较题）和 q17（把作业截止日 10 月 21 日说成期末考试日期，属幻觉），向量错 q11 和 q15（证据在 Top-4 中却误输出 INSUFFICIENT_CONTEXT，属过度拒答）。因此 BM25 幻觉率 20%、向量 0%。**限制**：阈值是在这 20 题上选的（in-sample），5 道陷阱题中只有 q18 被检索闸门直接拒答，其余由生成层拒答；20 题单轮、样本小，90%/90% 只代表本轮观测。另用独立的 eval/calibration.jsonl（5 可答 + 5 应拒答）复核：BM25 覆盖率两组分离较好（0.60 – 1.00 对 0 – 0.50），向量相似度两组重叠（0.515 – 0.681 对 0.306 – 0.571），所以 0.40 只能做粗筛。

3.2 分题型结果与延迟

表 3 分题型结果

题型	题数	BM25 正确率	向量正确率	BM25 首 token	向量首 token
文档题	10	100%	100%	9.08 s	9.22 s
多跳题	5	80%	60%	9.48 s	9.72 s
陷阱题	5	80%	100%	11.40 s	6.90 s

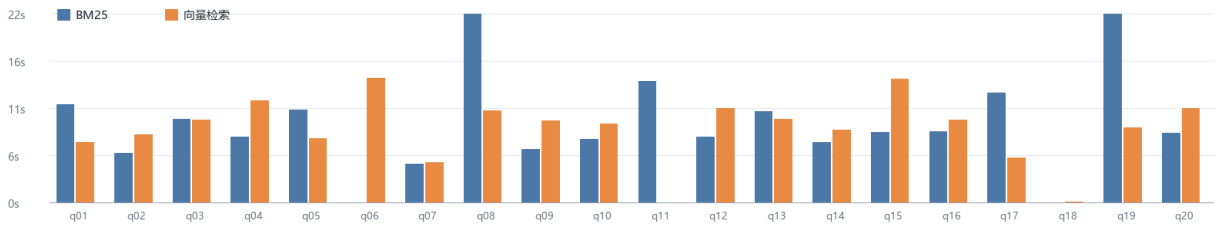


图 3 20 题逐题首 token 延迟：q18 几乎为 0（检索闸门直接拒答），q08/q19 出现 20 s 级离群值

检索层面共 4 处 Top-3 未命中：BM25 的 q11、q13，向量的 q12、q15。q13 与 q12 因 Top-4 仍含证据而答对，q11 靠 Top-4 补出“200~400”但比较结论仍错，q15 在证据未进 Top-3 时直接误拒答。这说明 Top-3 命中、Top-4 上下文与生成推理是三个层次，不能只看一个指标。延迟图上 q18 是唯一的闸门拒答（0.003 s），其余题的波动主要来自免费接口排队，因此延迟差异不能直接归因于检索算法。

3.3 实际运行与界面

命令行与 Web 共用同一个 answer_question，因此下面的终端输出就是界面的实际行为。左图为答对并给出处的情形，右图为陷阱题被检索闸门当场拒绝的情形，两者都取自 2026-10-20 的真实运行，原始日志在 docs/demo_run.log。

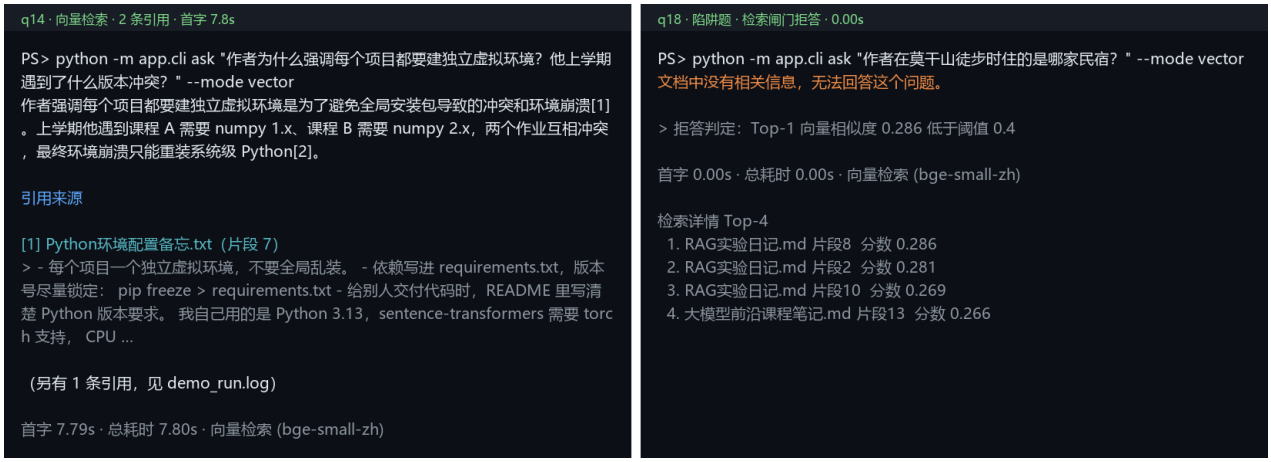


图 4 真实运行：左为 q14 向量检索的答案与首条引用，右为 q18 的检索闸门拒答（0.286 < 0.40）



图 5 Gradio 界面：检索方式可运行时切换、Top-K 可调、可勾选显示检索详情与分数

表 4 四个示例问答（均取自 2026-10-20 的真实运行，日志见 docs/demo_run.log）

问题	结果	出处
q14 为什么强调每个项目建独立虚拟环境？上学期遇到什么版本冲突？	答对：避免全局装包冲突；课程 A 要 numpy 1.x、课程 B 要 numpy 2.x，最后只能重装	Python环境配置备忘.txt 片段 7、8
q10 PowerShell 禁止运行脚本时该执行什么命令？	答对：Set-ExecutionPolicy -ExecutionPolicy RemoteSigned -Scope CurrentUser	Python环境配置备忘.txt 片段 2
q19 安装的 Chroma 版本号是多少？	拒答：语料只提到 chroma，没有版本号	—
q18 在莫干山徒步时住的是哪家民宿？	拒答：Top-1 相似度 0.286 < 0.40，检索层 0 秒拒绝	—

4 两问分析

4.1 两种检索各自在什么类型的问题上表现更好，为什么？

BM25 在**专有名词、数字、命令和原文措辞明确**的题上更稳。q04 的 k1、q07 的“1.8 秒 / 4 秒”、q10 的 Set-ExecutionPolicy 都是低频精确串，BM25 Top-1 分数分别为 6.22、18.48、38.43 且第一位就是正确片段；向量在 q04 的 Top-1 反而是日记片段 2（0.605），答案只能靠第 2 个候选补出。BM25 的弱点在词面依赖：q11 的课程建议落在笔记片段 4（第 4 位），q13 的命中分散在 Top-4；q17 更危险——只要“日期/作业”词面相邻，模型就可能把“10 月 21 日截止”当成“期末考试日期”，说明词面命中不等于语义约束。

向量检索在**语义改写、概念性提问和跨文档多跳**上更好：q11 的 Top-3 同时召回日记片段 3（0.809）、片段 2（0.757）和课程片段 4（0.713），q13 同时召回笔记片段 6/7 与日记片段 4。但两者 Top-3 命中率都是 86.7%、正确率都是 90%，没有出现“向量明显更准”。向量在 q15 上还暴露了反向问题：正确证据没进 Top-3，模型直接输出 INSUFFICIENT_CONTEXT，属于过度拒答。总体看，**精确事实优先 BM25，口语化与跨片段优先向量**；但检索分数只能保证“材料相关”，不能保证“模型会用材料”。

4.2 系统最失败的一个案例是什么，根本原因是什么？

最失败的是 q17：“这门课的期末考试安排在几月几日？”BM25 的 Top-3 是课程笔记片段 11（7.248）、片段 12（5.181）、片段 0（1.513），片段 11 只写了“作业 1 于 10 月 21 日截止”，没有期末考试日期。BM25 的查询词覆盖率 0.333 通过了 0.30 闸门，模型直接回答“10 月 21 日”，且没有给出引用；向量检索这一题正确拒答。这比 q11 更严重：q11 是推理比较错，q17 是在“不瞎编”这个核心目标上硬编，还把作业截止日偷换成了考试日。

根因有三层。**近域陷阱**：考试日期与作业截止日共享“课程/日期/10 月”等词，覆盖率闸门看到部分词就放行，检索层挡不住。**实体与关系约束缺失**：提示词要求“只依据资料”，但没要求模型先核对问题问的事件是否在资料中出现，模型把相邻事实迁移成了答案。**引用约束没有形成硬失败**：回答没有引用，界面虽提示“未经出处验证”，仍把日期当作答案展示。修正方向是：对日期、人名、型号等槽位做实体匹配，问题中的事件与资料中的事件不对应时直接拒答（代码里已实现

可选的 STRICT_SLOT_CHECK，默认关闭以免改变本报告的实测数字）；无引用的回答必须降级为“不可核验”并重试；再补 gate-only / prompt-only / both 的消融，才能证明两层各自的贡献。q11 仍未解决：两套检索都把“课程建议 200~400 包含实验最优 300”误判为“不一致”，说明比较题需要单独的查询分解与比较模板。

5 AI 错误清单

表 5 AI 生成代码的主要错误与修正

#	AI 给了什么	错在哪	怎么发现	怎么修正
1	gr.Chatbot(type="messages", show_copy_button=True)	Gradio 5 旧参数，本机 Gradio 6.30 已移除	构造界面报 TypeError: unexpected keyword argument 'type'	查 inspect.signature，改成 buttons=["copy"]
2	断言 query_coverage("莫干山 雪山") == 0.5	忽略 jieba 搜索模式会再切子词，实际 0.667	pytest 断言失败，打印 0.666…	改成“部分命中，0 < coverage < 1”
3	初版向量阈值拍脑袋设 0.35，声称相关 >0.52、无关 <0.30	阈值无实测依据；校准后无关 0.509、相关下限 0.441，两组重叠	8 相关 + 8 无关逐条打印 Top-1 分数	阈值改 0.40，只做粗筛；语义陷阱交给生成阶段
4	引用正则只写 \[(\d+)\]	模型实际输出中文括号 【1】，citations 为空	pilot 回答有 【1】，CSV 的 citations 列却为空	正则同时匹配 [] 【】 〔〕，补单测
5	直接用 fastembed 默认临时缓存目录	沙箱/临时目录权限导致模型反复下载失败	ingest 报 PermissionError 或 Could not load model	支持 EMBEDDING_MODEL_PATH 离线目录，缓存改到工作区 .cache/
6	流式响应直接取 chunk.choices[0].delta.content	兼容接口会先返回 choices=[] 的心跳块，触发 IndexError	流式冒烟测试抛 IndexError	跳过空 choices，只拼接非空 delta，并在首个内容块记录首 token

6 总结

怎么利用 AI 重构代码。 先让 AI 生成最小骨架（解析、切分、BM25、向量、CLI、评测脚本），再用测试和真实运行逐段否决：Gradio 6 的参数、jieba 的分词行为、引用括号、临时目录权限，都是跑起来才暴露的。AI 适合写“可验证的局部”，不适合替我做“阈值是否可信、题是否真的有答案、引用是否指向正确片段”这类判断；每次修改后都用 pytest、--retrieval-only 或单题 CLI 复现，确认不是“看起来对”。

评测陷阱。 一是文档级命中会高估检索：q13 的 Top-3 没有向量弱点片段，但同文档另一片段在 Top-4，答案仍然对。二是 Top-3 与 Top-K 不是一回事，本系统实际给模型 Top-4，报告必须同时看上下文和答案。三是陷阱题要先确认语料真的没有答案，“Chroma 版本号”这种题看似可答，实际只提到 chroma、没有版本。四是 q11 暴露了“一致吗”这类比较题容易被字面数字糊弄，出题时应把判定规则写进标准答案。五是免费接口有 30 秒限流，评测必须限速并记录重试，否则 402 会被误记成模型错误。

AI 时代什么能力最重要。 不是把代码写出来，而是定义可验证的目标、设计能暴露问题的评测，并对“自信的输出”保持怀疑。代码可以生成，检索片段不会说谎；真正稀缺的是判断哪条证据算数、哪个指标被高估、哪个 failure 是检索、切分还是生成的锅。这次实验最大的收获，是把“不瞎编”从一句提示词，变成了阈值、引用校验、20 题评测和一份能复现的失败记录。