不瞎编的私有知识库问答助手

姓名：温定浩 学号：2245014148 日期：2026-10-19

摘要：本实验实现了一个最小可用的个人知识库 RAG 问答助手，支持 PDF、Markdown、TXT 导入，采用 300 字切分，并可在运行时切换 BM25 与 bge-small-zh 向量检索。系统在生成阶段强制标注原文出处，并通过检索阈值与生成约束两层机制实现拒答。实验使用 20 道自建题（10 道文档题、5 道陷阱题、5 道多跳题）对两种检索各运行一遍，从答案正确率、幻觉率、Top-3 检索命中率和首 token 延迟四个维度进行比较，并定位了一个“检索证据齐全却仍答错”的多跳案例。

关键词：检索增强生成；BM25；向量检索；拒答；引用溯源；评测

1 系统架构

系统分为四层。**语料层**把 PDF、Markdown、TXT 解析为统一文本，按段落或句子优先切成 300 字片段，相邻片段保留约 50 字的整句重叠。**索引层**为同一批片段分别建立 BM25 倒排统计和 512 维归一化向量索引，向量由本地 bge-small-zh-v1.5（fastembed，CPU）生成。**检索层**用统一的 search(query, top_k) 接口封装两个检索器，Web 与 CLI 只改一个参数即可切换。**生成层**把 Top-K 片段编号后拼进提示词，要求每个关键结论标注 [n]；程序只接受落在候选范围内的编号，再把编号还原成“文档名 + 片段号 + 原文片段”。

拒答有两道闸门：检索层用向量 Top-1 相似度（< 0.40）或 BM25 查询词覆盖率（< 0.30）挡住明显域外问题；生成层要求模型在资料不足时只输出 INSUFFICIENT_CONTEXT，程序同时识别中英文拒答措辞。第一层不调用模型、延迟低，第二层负责“词面相关但实际答不了”的陷阱。

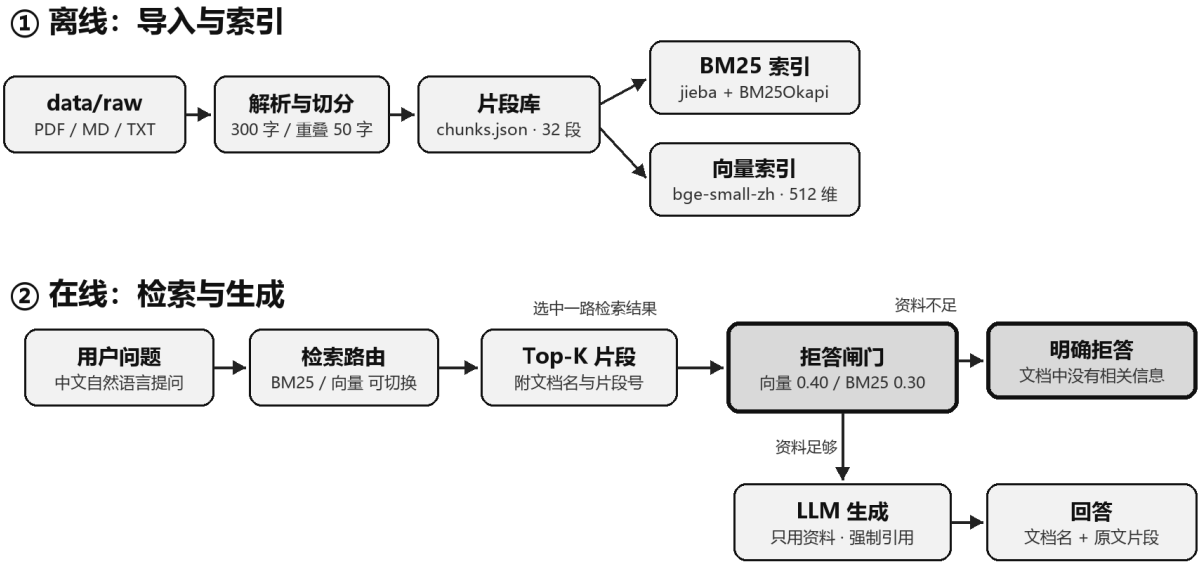


图 1 系统架构：从语料导入、双索引检索到带引用的生成与两层拒答

2 实验设置

表 1 实验设置

项目	设置
语料	3 个文档、5 781 字符、2 种格式；最长一篇纯汉字 1 530、按“汉字+英文/数字串”计 1 635，均超过 1 500，口径见 data/README.md
切分	300 字 / 约 50 字整句重叠（0 - 100）；3 个文档共 32 个片段；依据是日记中 8 题切分实验：200/300/500 字 Top-3 命中分别为 5/8、7/8、6/8
关键词检索	jieba 搜索模式分词 + rank-bm25 BM25Okapi，Top-4
向量检索	BAAI/bge-small-zh-v1.5，512 维，余弦相似度，Top-4
生成	OpenAI 兼容接口（测试用 Pollinations openai-fast），temperature=0，流式输出；提示词禁止使用资料外知识、强制引用
拒答阈值	向量 Top-1 < 0.40；BM25 查询词覆盖率 < 0.30；阈值在这 20 题上校准（in-sample，限制见 3.1）
评测集	20 题：10 文档题、5 陷阱题、5 多跳题；每题标注标准答案、来源文档、原文 evidence
环境	Windows 11，i5-12400 / 16 GB / 无显卡；Python 3.13.9、gradio 6.30.0、fastembed 0.9.0

3 评测结果

3.1 四项指标

表 2 两种检索方案的四项指标

指标	BM25	向量检索
答案正确率	90%（18/20）	90%（18/20）
幻觉率（5 道陷阱题）	20%（1/5）	0%（0/5）
Top-3 检索命中率	86.7%（13/15）	86.7%（13/15）
首次回答平均延迟（首 token）	9.76 s	8.77 s
端到端平均延迟（参考）	10.42 s	9.14 s
引用给出率	93.3%（14/15）	100%（14/14）
引用文档准确率	100%	100%

BM25 和向量检索各答对 18/20。BM25 的两个错误是 q11（比较题）和 q17（把作业截止日 10 月 21 日说成期末考试日期，属于幻觉）；向量的两个错误是 q11（同一个比较题）和 q15（证据在 Top-4 中，却误输出 INSUFFICIENT_CONTEXT）。因此 BM25 的陷阱题正确率只有 80%，幻觉率 20%；向量陷阱题 100% 正确、幻觉率 0%。两者的 Top-3 命中率相同（86.7%），但答案正确率也相同，说明本轮的检索命中与生成正确性没有拉开差距，不能支持“某一种检索更准”的强结论。

延迟上 BM25 首 token 9.76 s、端到端 10.42 s，向量为 8.77 s / 9.14 s。评测脚本没有把检索与生成分项计时，因此不能把差异直接归因于检索；免费接口排队是主要嫌疑，且均值受个别 20 s 级离群值影响，TTFT 中位数为 8.15 s（BM25）/ 9.54 s（向量），排序与均值相反，说明延迟差异不稳健。

引用核验：生成时按句计算答案与候选片段的 token 重叠，q02 等早期出现的“编号在范围内但不支撑句子”会被重映射或删除。最终 15 道有答案题中，BM25 14 道有引用、向量 14/14 有引用；引用片段全部来自 source_docs，文档准确率 100%。q02 BM25 的回答没有生成引用，因此引用给出率是 93.3%，没有拿 Top-3 资料冒充引用。

限制：阈值最初是在这 20 题上选择的（in-sample）；5 道陷阱题中只有 q18 被检索闸门直接拒答，q16/q17/q19/q20 都由生成层拒答；20 题单轮、2 题差异和 5 题容量都太小，95% 置信区间很宽。因此 90%/90%、20%/0% 只代表本轮观测，不作为泛化结论。另用独立的 eval/calibration.jsonl（5 个可答题 + 5 个拒答题）复核：BM25 coverage 可答题 0.60 – 1.00、拒答题 0 – 0.50，分离较好；向量相似度可答题 0.515 – 0.681、拒答题 0.306 – 0.571，两组重叠，所以向量阈值 0.40 只能做明显域外问题的粗筛。

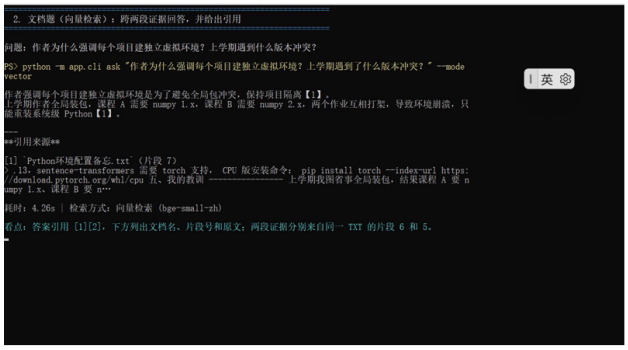
3.2 分题型结果

表 3 分题型结果

题型	题数	BM25 正确率	向量正确率	BM25 首 token	向量首 token
文档题	10	100%	100%	9.08 s	9.22 s
多跳题	5	80%	60%	9.48 s	9.72 s
陷阱题	5	80%	100%	11.40 s	6.90 s

检索层面共有 4 处 Top-3 未命中：BM25 的 q11（课程笔记片段 4 排第 4）和 q13，向量的 q12 和 q15。BM25 的 q13、向量的 q12 因为 Top-4 仍包含证据而答对；BM25 的 q11 靠 Top-4 补出“200~400”，但比较结论仍错；向量的 q11 证据齐全却同样答错；向量的 q15 则是在证据未进 Top-3 的情况下直接误拒答。这说明 Top-3 命中、Top-4 上下文和生成推理是三个不同层次，不能只看一个指标。

3.3 录屏截图



q14 向量检索：两段证据与引用



q19 陷阱题：生成层拒答

图 2 录屏截图：左为 q14 向量检索的引用，右为 q19 的生成层拒答（取自 docs/演示录屏.mp4，01:10 / 02:15）

左图展示答案末尾的 [1] 与 Python环境配置备忘.txt 片段 7 的原文；右图展示语料没有 Chroma 版本号时，模型输出“文档中没有相关信息”，并标注“模型判断资料不足以回答”。两图分别对应“引用可核验”和“不知道就说不知道”两个核心行为。

4 两问分析

4.1 两种检索各自在什么类型的问题上表现更好，为什么？

BM25 在**专有名词、数字、命令和原文措辞明确**的文档题上更稳。q04 的 k1、q07 的“1.8 秒 / 4 秒”、q10 的 Set-ExecutionPolicy 都是低频精确串，BM25 Top-1 分数分别达到 6.22、18.48、38.43，且第一位就是正确片段；向量检索在 q04 的 Top-1 反而是日记片段 2（0.605），答案只能靠第 2 个候选补出。BM25 的弱点在词面依赖和分片边界：q11 的课程建议落在笔记片段 4（第 4 位），q13 的向量弱点和命中率也分散在 Top-4；q17 则暴露了更危险的一面——只要“日期/作业”等词面相邻，模型就可能把“10 月 21 日截止”当成“期末考试日期”，说明词面命中不等于语义约束。

向量检索在**语义改写、概念性提问和跨文档多跳**上更好：q11 的 Top-3 同时召回日记片段 3（0.809）、片段 2（0.757）和课程片段 4（0.713），q13 同时召回笔记片段 6/7 与日记片段 4。但两者 Top-3 命中率最终都是 86.7%，答案正确率也都是 90%，没有出现“向量明显更准”。向量在 q15 上还暴露了反向问题：正确证据没有进 Top-3，模型直接输出 INSUFFICIENT_CONTEXT，属于过度拒答；q11 虽然证据齐全，却仍把“三者命中率不同”误当成“课程建议与实验结论不一致”。总体看，**精确事实优先 BM25，口语化/跨片段优先向量**；但检索分数只能保证“材料相关”，不能保证“模型会正确使用材料”，两者都需要来源感知、比较推理和实体约束。

4.2 系统最失败的一个案例是什么，根本原因是什么？

最失败的案例是 q17：“这门课的期末考试安排在几月几日？”BM25 的 Top-3 是课程笔记片段 11（7.248）、片段 12（5.181）、片段 0（1.513）；片段 11 只写了“作业 1 于 10 月 21 日截止”，并没有期末考试日期。BM25 的查询词覆盖率 0.333 通过了 0.30 闸门，模型直接回答“10 月 21 日”，没有给出引用。向量检索这一题正确拒答。标准答案是“文档中没有相关信息”。这是比 q11 更严重的失败：q11 是推理比较错，q17 是系统在“不瞎编”这个核心目标上硬编了一个日期，且把作业截止日偷换成了考试日。

根因有三层。第一层是**近域陷阱**：考试日期与作业截止日共享“课程/日期/10 月”等词，BM25 覆盖率闸门看到部分词就放行；q17 不是完全域外问题，检索层挡不住。第二层是**实体与关系约束缺失**：提示词要求“只依据资料”，但没有要求模型先核对“问题问的事件/实体”是否在资料中明确出现；模型把“作业截止”这个相邻事实迁移成“期末考试”。第三层是**引用约束没有形成硬失败**：回答没有引用，界面虽显示“未经出处验证”，但仍把日期作为答案展示，没有触发拒答或重试。修正方向是：对日期/人名/型号等槽位做实体匹配，问题中的事件和资料中的事件不完全对应时直接拒答；无引用的回答必须降级为“不可核验”并重试/拒答；同时增加 gate-only / prompt-only / both 的消融和更多近域陷阱，才能证明两层拒答各自的贡献。q11 仍未解决：两套检索都把“课程建议 200~400 包含实验最优 300”误判成“不一致”，说明比较题的查询分解和比较模板还需要单独实现。

5 AI 错误清单

表 4 AI 生成代码的主要错误与修正

#	AI 给了什么	错在哪	怎么发现	怎么修正
1	gr.Chatbot(type="messages", show_copy_button=True)	Gradio 5 旧参数，本机 Gradio 6.30 已移除	构造界面报 TypeError: unexpected keyword argument 'type'	查 inspect.signature，改成 buttons=["copy"]
2	断言 query_coverage("莫干山 雪山") == 0.5	忽略 jieba 搜索模式会把“莫干山”再切成子词，实际 0.667	pytest 断言失败，打印 0.666…	改成“部分命中，0 < coverage < 1”，补完全无关为 0 的断言
3	初版向量阈值拍脑袋设 0.35，并声称相关 >0.52、无关 <0.30	阈值没有实测；校准后无关问题 0.509，相关问题下限 0.441，两组重叠	8 个相关 + 8 个无关问题逐条打印 Top-1 分数	阈值改 0.40，只做粗筛；语义陷阱交给生成阶段
4	引用正则只写 \[(\d+)\]	模型实际输出中文括号 【1】，citations 为空	pilot 回答有 【1】，CSV 的 citations 列却为空	正则同时匹配 [] 【】 〔〕，补单测
5	直接用 fastembed 默认临时缓存目录下载模型	沙箱或临时目录权限导致下载反复失败，索引建不起来	ingest 报 PermissionError 或 Could not load model	支持 EMBEDDING_MODEL_PATH 离线模型目录，缓存改到工作区 .cache/
6	流式响应直接取 chunk.choices[0].delta.content	兼容接口会先返回 choices=[] 的 usage/心跳块，触发 IndexError	流式冒烟测试抛 IndexError: list index out of range	跳过空 choices，只拼接非空 delta，并用首个内容块记录首 token

6 总结

怎么利用 AI 重构代码。 我先让 AI 生成最小骨架（解析、切分、BM25、向量、CLI、评测脚本），再用测试和真实运行逐段否决：Gradio 6 的参数、jieba 的分词行为、引用括号、临时目录权限，都是跑起来才暴露的。AI 适合写“可验证的局部”，不适合替我做“阈值是否可信、题是否真的有答案、引用是否指向正确片段”这类判断。每次修改后我都用 pytest、--retrieval-only 或单题 CLI 复现，确认不是“看起来对”。

评测陷阱。 第一，文档级命中会高估检索：q13 的 Top-3 没有向量弱点片段，但同文档另一片段在 Top-4，答案仍然对，若只按文档名判分会看不出缺口。第二，Top-3 与 Top-K 不是一回事：本系统实际给模型 Top-4，所以“Top-3 命中率”低不代表答错，报告必须同时看上下文和答案。第三，陷阱题要先确认语料真的没有答案；“Chroma 版本号”这种题看似可答，实际只提到 chroma、没有版本。第四，q11 暴露了“一致吗”这种比较题容易被模型用字面数字糊弄，出题时应把判定规则写进标准答案。第五，免费接口有 30 秒限流，评测必须限速并记录重试，否则 402 会被误记成模型错误。

AI 时代什么能力最重要。 不是把代码写出来，而是定义可验证的目标、设计能暴露问题的评测，并对“自信的输出”保持怀疑。代码可以生成，检索片段不会说谎；真正稀缺的是判断哪条证据算数、哪个指标被高估、哪个 failure 是检索、切分还是生成的锅。这次实验最大的收获，是把“不瞎编”从一句提示词，变成了阈值、引用校验、20 题评测和一份能复现的失败记录。